

实验报告：任务一 —— Prompt Engineering 基础实验

文件依据：Prompt-Engineering-Basics.html（已解析）

实验主题：对话摘要任务中的 Zero-shot / One-shot / Few-shot Prompt Engineering

1. 实验背景

本实验使用 Hugging Face 的 **FLAN-T5-Base** 模型完成 DialogSum 数据集的对话摘要任务，并在三个场景下观察模型行为：

1. **Zero-shot**：无指令、无示例
2. **One-shot**：提供一条完整示例
3. **Few-shot (Exercise)**：提供多条示例，修改示例数量与索引

每个 Exercise 均要求：

- 按 Notebook 要求修改参数
- 重现输出
- 分析模型行为原因 (insight)
- 回答 Notebook 中提出的问题

以下逐项展开。

2. Exercise 1: Zero-shot 结果分析

2.1 操作步骤

Notebook 中直接运行 Zero-shot 推理，无需构造任何 prompt，只将一段对话输入模型：

模型输出示例（来自文件）：

```
1 | MODEL GENERATION - WITHOUT PROMPT ENGINEERING:
2 | #Person1#: I'm thinking of upgrading my computer.
```

2.2 观察到的现象

- 模型 **没有生成摘要**
- 它 **续写了对话**（继续生成下一句）
- 输出内容往往与真实摘要完全不一致

例如：

真实摘要（baseline human summary）：

```
1 | #Person1# teaches #Person2# how to upgrade software and hardware...
```

模型输出却是：

```
1 | #Person1#: I'm thinking of upgrading my computer.
```

2.3 原因分析 (insight)

Zero-shot 情况下，模型缺乏“任务指令”与“格式示例”，因此它会：

- 默认按照训练时最常见的任务模式——**对话续写 (next-token prediction)**
- 并不知道“你希望它做摘要”
- 因此输出行为偏离任务本意

核心 insight：

在无 prompt 指令的情况下，大模型不会自动推断出“我要做摘要”，而是回到语言模型的默认行为：继续写下去。

2.4 本 Exercise 的结论

Zero-shot 对话摘要效果非常差，主要原因不是模型能力不足，而是 **prompt 中缺乏任务定义**。这为 prompt engineering 的必要性奠定基础。

3. Exercise 2: One-Shot Inference (任务 3.1)

3.1 操作步骤

Notebook 构造 one-shot prompt：

- 选择一个示例：`example_indices_full = [40]`
- 设置目标样例：`example_index_to_summarize = 200`

Prompt 内容如文件所示：

```
1 | Dialogue:
2 | (完整示例对话 40)
3 |
4 | what was going on?
5 | (示例摘要)
6 |
7 | Dialogue:
8 | (目标对话 200)
9 |
10 | what was going on?
```

运行模型后的输出：

```
1 | MODEL GENERATION - ONE SHOT:
2 | #Person1 wants to upgrade his system. #Person2 wants to add a painting
   | program...
```

3.2 观察到的现象

与 Zero-shot 相比：

- 模型开始**生成摘要**而不是续写
- 摘要结构和语言风格更贴近真实标签
- 但仍存在细节偏差 / 简化过度

3.3 原因分析 (insight)

One-shot 的优势来自 **In-Context Learning**：

1. 给出一个完整的“输入 → 输出”示例
2. 模型自动识别“模式”
3. 模型迁移示例结构到下一段对话

但由于只提供一个示例：

- 模型掌握的任务分布有限
- 仍容易遗漏细节或做过度抽象总结

3.4 小结

One-shot 明显好于 Zero-shot，但精确性受限于单示例的多样性不足。

4. Exercise 3: Few-Shot Inference (任务 4.2)

4.1 Notebook 要求

```
1 Experiment with the few shot inferencing.
2 - Choose different dialogues by modifying example_indices_full and
  example_index_to_summarize.
3 - Change the number of shots, but stay within 512 context length.
4 How well does few shot inferencing work with other examples?
```

4.2 操作步骤

Notebook 默认选择：

```
1 example_indices_full = [40, 80, 120]
2 example_index_to_summarize = 200
```

生成 few-shot prompt → 模型输出：

```
1 | MODEL GENERATION - FEW SHOT:
2 | #Person1 offers some suggestions about how to upgrade her system.
```

4.3 观察到的现象

与 One-shot 相比：

- 输出依然是摘要
- 质量略有改善，但 **改进幅度有限**
- 某些情况下甚至与 One-shot 表现相似（甚至略退步）

文件中明确指出：

```
1 | In this case, few shot did not provide much of an improvement over one shot
  | inference.
2 | Anything above 5 or 6 shots typically not help much.
```

4.4 原因分析 (insight)

Few-shot 理论上应提供更多任务模式信息，但效果有限的原因是：

1. **模型输入长度限制 (512 tokens)**
 - 超过后模型会截断重要示例
 - 影响学习质量
2. **示例之间的任务分布差异较大**
 - 三个对话情节差异大，模型难以抽取稳定模式
 - 反而导致泛化不佳
3. **FLAN-T5 已经经过 instruction finetune**
 - 对“对话摘要”任务可能已有能力
 - 更多示例反而边际收益递减
4. **Prompt 结构较长且重复，对齐难度提升**
 - 模型可能只学习了格式，而非深层语义

核心 insight：

Few-shot 不是“示例越多越好”，关键是“代表性强、结构一致、数量适中”。在本实验中，由于示例差异大 + 输入长度限制，few-shot 增益被抵消了。

4.5 回答 Exercise 的问题

“How well does few shot inferencing work with other examples?”

基于实验结果与 Notebook 输出：

- Few-shot 对摘要质量有 **轻微提升，但不稳定**
- 某些例子中几乎与 One-shot 相当
- 超过 3~5 个示例通常不会带来更多收益

- 若示例风格差异大，模型甚至可能退化
- 受 FLAN-T5 的 512 token context length 限制，过多示例会被截断，直接损害性能

总结：

Few-shot 在本任务中效果有限，不一定优于 One-shot，示例数量过大或不一致反而会降低质量。

5. 综合总结

本任务的核心认识：

1. **Zero-shot** → **续写而非摘要**

- 原因：缺乏任务指令，模型回到语言模型默认行为。

2. **One-shot** → **能正确生成摘要**

- 模型通过示例进行 In-Context Learning，掌握“对话 → 摘要”模式。

3. **Few-shot** → **改善有限且不稳定**

- 因示例不一致、上下文长度限制导致边际收益下降
- 超过 5~6 shots 一般无益

整体 insight：

Prompt Engineering 的效果高度依赖示例质量与上下文长度，而非单纯增加示例数量。