

实验报告：任务三 —— 使用强化学习 (PPO) 实现大模型对齐 (Alignment)

实验文件：Align-LLM-PPO.html

任务目标：探索如何使用 **PPO (Proximal Policy Optimization)** 对大模型进行对齐，使其输出更符合人类偏好。

使用的模型：distilgpt2 (轻量模型，便于教学)

强化学习框架：TRL (HuggingFace Transformers Reinforcement Learning)

1. 实验背景与流程概述

任务三核心思路：

1. **定义 prompt** (如 “Write a positive movie review”)
2. **构建奖励模型 (reward function)**
 - 本实验使用 **情感分类器** 作为奖励模型
 - 积极情感 (positive sentiment) 得分更高
3. **使用 PPO 对语言模型进行 RL 微调**
 - Actor 模型：待训练的 LLM
 - Reference 模型：保持冻结，用于 KL penalty
4. **对比强化学习前后的模型输出与奖励变化**
5. **解释差异来源**

RLHF 的目标是：

模型不仅要语言流畅，还要“符合偏好”（正向情感）。

2. 强化学习前的模型表现 (Pre-RL Baseline)

文件显示 baseline 生成如下内容：

```
1 ----- Pre-trained model generate -----
2 this movie is so boring and predictable...
```

2.1 观察现象

- 输出带有明显负面情绪：boring、predictable
- 与 Prompt “写一段正向评价 (positive review)” 不一致
- 模型缺乏 alignment，不理解“人类希望输出积极评论”的偏好

2.2 预训练模型奖励评分 (pre-RL reward)

文件中给出的奖励函数输出示例：

```
1 | reward: -0.11
```

insight (为什么奖励低?)

1. 预训练模型没有学习“正向偏好”

GPT 预训练目标是语言建模，不关心情绪方向。

2. 生成倾向真实分布：电影评论中负面比例很高

训练语料中大量消极影评，因此“boring/predictable”是常见 token 模式。

3. 奖励模型认为输出情绪是负面的

因此 reward 小于 0。

=> 这正是 RLHF 的意义所在：让模型输出**偏好一致**而非仅仅**可能出现的语言**。

3. PPO 强化学习训练过程

文件显示 PPO 的训练日志：

```
1 | Step: 1 | KL: 0.23 | Reward: 0.13
2 | Step: 2 | KL: 0.19 | Reward: 0.28
3 | Step: 3 | KL: 0.15 | Reward: 0.31
4 | ...
5 | Step: 50 | KL: 0.10 | Reward: 0.59
```

3.1 关键现象

- **Reward 从负值 → 正值 → 持续上升**
- KL penalty 保持在 0.1-0.2 之间
表示模型生成有变化，但不会偏离 reference 过远
- 训练稳定，PPO 成功提升“正向情绪”奖励

insight (为什么 reward 会变高?)

1. PPO 强制模型朝奖励方向优化

奖励模型给正向句子打更高分，因此 PPO 更新后模型倾向于生成积极表达。

2. KL penalty 限制模型崩坏

KL 越大表示偏离 reference 越大；PPO 的 clipping 控制它保持稳定。

3. 语言模型从负面倾向 → 积极风格

训练逐步推高 “positive sentiment” token 的概率（如 great, amazing, wonderful）。

4. 强化学习后的模型表现 (Post-RL / PPO-tuned)

强化学习后的生成示例（来自文件）：

```
1 ----- Optimized model generate -----
2 This movie is wonderful and full of heart...
```

4.1 明显变化

- 情绪明显正向：wonderful, full of heart
- 与 prompt 完全对齐
- 内容长度更丰富
- 风格更像真实影评人

4.2 RL 后奖励评分 (post-RL reward)

文件中的奖励输出：

```
1 reward: 0.72
```

4.3 Pre-RL vs Post-RL 对比

指标	Pre-RL	Post-RL
生成风格	消极、含负向词	明显正向，符号偏好
奖励值	-0.11	0.72
任务对齐程度	低	高
是否符合 prompt	多为偏离	完全符合

insight：为何 RL 后效果提升巨大？

1. 奖励模型直接优化目标行为

PPO 让语言模型将奖励信号作为优化方向，使得“正向内容”概率提高。

2. 对齐机制明确：模型被训练“讨好奖励”

语言模型希望最大化 expected reward，自然倾向输出更正面的语句。

3. KL regularization 防止模型乱码

在提升情感方向的同时，PPO 保持语言质量不下降。

4. 强化学习是“行为层面”的对齐

与 supervised finetuning 不同：

- SFT：学习“是什么”
 - RLHF：学习“人类更喜欢什么”
- 因此强化学习必然提升偏好一致性。

5. 总结：差异产生的核心原因

综合本实验观察：

1. 预训练模型未对齐人类偏好 (reward 低)

- 不理解任务目标

- 生成“看似合理但不符合预期”的内容

2. PPO 让模型学习奖励模型的偏好 (reward 上升)

- 优化方向变得清晰：多生成正向词
- Output distribution 向 positive sentiment shift

3. KL penalty 维持语言质量

- 限制模型偏离 reference model，使语言仍然自然

4. 强化学习后的模型更“听话”

- Prompt 对齐度更高
- 行为在 reward function 定义的空间内更稳定

5. PPO 的收敛过程体现了 alignment 的本质

- 奖励越高 → 行为越符合偏好
- 这也是 RLHF 能让大模型更像“对齐人类价值观”的根本原因

6. 结语

任务三的实验充分展示：

- 监督微调 (SFT) 解决“能不能做任务”
- 强化学习 (RLHF/PPO) 解决“做得是否符合人类偏好”

通过奖励模型 + PPO，我们能够让语言模型

从“会做任务” → “做得让人满意”。

本实验中，奖励显著提升、输出风格完全对齐 prompt，是 RLHF 成功的标志。